



Hands on - análise de dados básica

objetivos

- Realizar uma análise de dados simples
 - visualizar dados
 - manipular ntuple (TTree) de dados
 - produzir, processar e exibir histogramas de dados
 - selecionar sinal de física
 - plotar distribuições cinemáticas
 - critérios de seleção
 - extrair parâmetros físicos dos dados
 - medir os yields do sinal realizando um ajuste de probabilidade (likelihood fit) aos dados
 - incertezas estatísticas

Parte I


https://colab.research.google.com/drive/1sHo06MJh_yzv-n_s2WzfaMM6Jd9yPWey?usp=sharing

Parte II

<https://colab.research.google.com/drive/1EmlghSAaxVjUp1HZAiOabbBmjZqZwW8b?usp=sharing>

https://github.com/INCT-CERN-Brasil/Escola2024/blob/main/dia_01/ExercicioManipulandoDados_EscolaINCT_Partel_v1.ipynb


eventos de dimúons ($x \rightarrow \mu\mu$)




CMS-PHO-EVENTS-2022-031

o espectro de **dimuon** ($X \rightarrow \mu^+ \mu^-$)

Décadas de descobertas em física de partículas... em um único gráfico!



massa invariante de dimúons






identificação de partículas
 - sinal nas câmaras de múons
 → é um múon!
 ⇒ $m = m(\mu) \sim 106 \text{ MeV}/c^2$

trajetória da partícula
 - câmaras de múons, mas especialmente o silicon tracker
 ⇒ momentum linear , $p=(p_x, p_y, p_z)$


⇒ 4-momentum de cada múon:
 $\mathbf{P}=(E, p_x, p_y, p_z)$ ou $\mathbf{P}=(p_T, \eta, \phi, M)$ para $E \gg m$
 ⇒ para o par de dimuon: $\mathbf{P}_{\mu\mu} = \mathbf{P}_{\mu 1} + \mathbf{P}_{\mu 2}$
 ⇒ massa invariante: $M_{\mu\mu} = (\mathbf{P}_{\mu 1} + \mathbf{P}_{\mu 2})^2$

outras variáveis



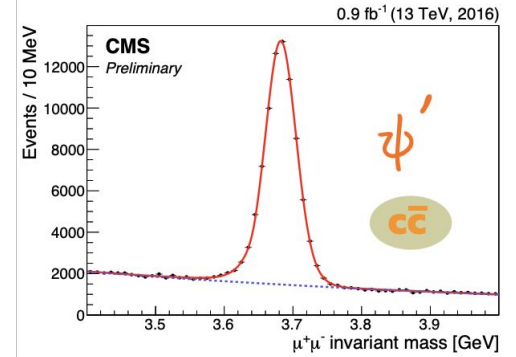


CMS



o espectro do dimuon reconstruído




o que são os picos?




suas propriedades podem ser consultadas aqui: <https://pdglive.lbl.gov/Viewer.action>

zoom... e seleccione um sinal



ajuste aos dados



Inspeção da qualidade do ajuste
 o ajuste pode ser melhorado?

dica: a radiação do estado final
 $(\mu \rightarrow \mu\gamma)$ pode distorcer a forma.

Passos:

Estabelecer um modelo de ajuste

senal: gaussiana

fundo: polinomial

Extrair parâmetros do sinal

yields ($N \pm \sigma_N$), massa ($m \pm \sigma_m$)

Estimar as incertezas sistemáticos

a escolha do modelo afeta os resultados
 medidos?

quantificar as variações sistemáticas
 empregando diferentes modelos

Apresentar as medidas finais ($N \pm \sigma_{\text{esta}} \pm \sigma_{\text{sis}}$)

Análise de forma Colunar - uproot

- O uproot é um módulo Python que permite ler e escrever arquivos no formato ROOT.
- A dependência obrigatória, além do próprio Python, é o NumPy, que é a biblioteca mais popular para manipulação de arrays de dados em Python.
- Ele é capaz de processar grandes volumes de dados de forma rápida.



```
import uproot
file = uproot.open("data.root")
file
```

Saída: <ReadOnlyDirectory '/' at 0x(some hexadecimal number here)>

Análise de forma Colunar - uproot

Como navegar e acessar o conteúdo do arquivo ROOT usando o uproot?

Ex.:

Listar o conteúdo do arquivo:

```
file.keys()
```

```
# Saída: ['Events;1']
```

Verificar o tipo de objeto no arquivo:

```
file.classnames()
```

```
# Saída: {'Events;1': 'TTree'}
```

Acessar o conteúdo do arquivo (file['key']):

```
file['Events']
```

```
# Saída: <TTree 'Events' (6 branches) at 0x(hexadecimal number)>
```

Como acessar e manipular a TTree do arquivo ROOT usando o uproot?

```
tree = file['Events']
```

```
tree.keys()
```

```
#Saída: ['nMuon', 'Muon_pt', 'Muon_eta', 'Muon_phi', 'Muon_mass',  
'Muon_charge']
```

```
tree.arrays()
```

```
#Saída: <Array [{nMuon: 2, Muon_pt: [10.8, ... -1, 1]}] type='100000 *  
uint32,...'>
```

```
branches = tree.arrays()
```

```
branches['nMuon']
```

```
#Saída: <Array [2, 2, 1, 4, 4, 3, ... 0, 3, 2, 3, 2, 3] type='100000 *  
uint32'>
```

Quando usamos `tree.arrays()`, ele retorna um objeto Awkward Array.

Como acessar e manipular a TTree do arquivo ROOT usando o uproot?

```
branches['Muon_pt']
```

```
#Saída: <Array [[10.8, 15.7], ... 11.4, 3.08, 4.97]] type='100000 * var * float32'>
```

São arrays irregulares (jagged array), pois o número de entradas ('nMuon') varia por evento.

Para acessar os dados de um evento específico, você pode indexar o array como faria com qualquer array normal.

```
branches['Muon_pt'][0]
```

```
#Saída:<Array [10.8, 15.7] type='2 * float32'>
```


Análise de forma Colunar - Awkward Array

Os dados em altas energias são estruturados de forma irregulares:

Awkward
Array

- Não pode ser representado como uma tabela “retangular”.
 - Em diferentes eventos - números variáveis de objetos, como μ /e/jatos/...

A representação de Arrays Irregulares (Jagged Arrays):

Muon pt: table

Event 1	40.2	25.6	10.2
Event 2	71.1	35.7	
Event 3	52.3		
Event 4	34.5	15.7	

Muon pt: jagged array

[[40.2	25.6	10.2]	[71.1	35.7]	[52.3]	[34.5	15.7]]
	Event 1		Event 2		Event 3		Event 4

Análise de forma Colunar - Awkward Array

Como aplicamos seleções em arrays irregulares (jagged arrays)?

- Usando máscaras.

`mu_pt` =

40.2	25.6	10.2
71.1	35.7	52.3
34.5	15.7	

`mask = (mu_pt > 30)` =

T	F	F
T	T	T
T	F	

`mu_pt[mask]` =

40.2	
71.1	35.7
52.3	34.5

A máscara foi aplicada a cada múon em cada evento de maneira vetorizada.

Análise de forma Colunar - Awkward Array

```
✓ 4s [9] 1 !pip install awkward
      2 import awkward as ak
      3 import numpy as np

      Show hidden output

✓ 0s [9] 1 mu_pt = ak.Array([[40.2, 25.6, 10.2], # Evento 1: três múons
      2                               [71.1, 35.7],      # Evento 2: dois múons
      3                               [52.3],             # Evento 3: um múon
      4                               [34.5, 15.7]])      # Evento 4: dois múons

✓ 0s [10] 1 mask_mupt = mu_pt > 30
        2 mu_pt_sel = mu_pt[mask_mupt]

✓ 0s [11] 1 print("Array original:", mu_pt)
        2 print("\nMáscara aplicada:")
        3 print(mask_mupt)
        4 print("\nArray após a aplicação da máscara:")
        5 print(mu_pt_sel)

      Show hidden output

      Array original: [[40.2, 25.6, 10.2], [71.1, 35.7], [52.3], [34.5, 15.7]]


      Máscara aplicada:
      [[True, False, False], [True, True], [True], [True, False]]

      Array após a aplicação da máscara:
      [[40.2], [71.1, 35.7], [52.3], [34.5]]
```

Análise de forma Colunar - Matplotlib

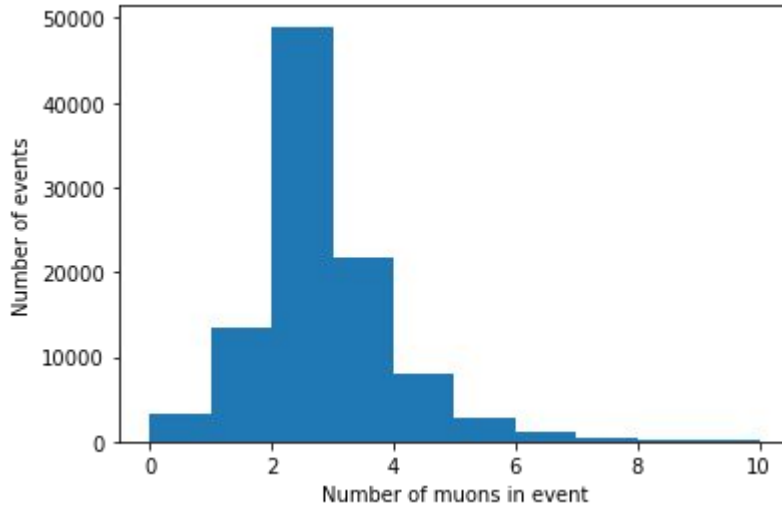
```
import matplotlib.pyplot as plt  
plt.hist(branches['nMuon'])
```

```
#Saída:(array([8.7359e+04, 1.2253e+04, 3.5600e+02,  
2.8000e+01, 2.0000e+00,1.0000e+00, 0.0000e+00,  
0.0000e+00, 0.0000e+00, 1.0000e+00]),array([ 0.,3.9,  
7.8, 11.7, 15.6, 19.5, 23.4, 27.3, 31.2, 35.1, 39. ]),  
<a list of 10 Patch objects>)
```



Análise de forma Colunar - Matplotlib

```
plt.hist(branches['nMuon'], bins=10, range=(0, 10))  
plt.xlabel('Number of muons in event')  
plt.ylabel('Number of events')  
plt.show()
```




Matplotlib

Análise de forma Colunar - Matplotlib

Para fazer um histograma de um array irregular (jagged array), precisamos converter o array 2D para 1D usando o Awkward Array com a função `ak.flatten()`. Ex.:

```
import awkward as ak
```

```
plt.hist(ak.flatten(branches['Muon_pt']), bins=100, range=(0, 100))  
plt.xlabel('Muon  $p_{\mathrm{T}}$  [GeV]')  
plt.ylabel('Number of muons / 1 GeV')  
plt.show()
```



Análise de forma Colunar - Contagem

```
len(branches['Muon_pt']) #número total de eventos
```

```
#Saída: 100000
```

```
len(ak.flatten(branches['Muon_pt'])) #número total de múons
```

```
#Saída: 235286
```

Análise de forma Colunar - Seleções

Para seleções:

```
branches['nMuon']== 1 # o resultado é array booleano
```

```
#Saída:<Array [False, False, True, ... False, False] type='100000 * bool'>
```

Para contar quantos eventos atendem a essa condição:

```
single_muon_mask = branches['nMuon']== 1
```

```
np.sum(single_muon_mask) #Saída: 13447
```

Para selecionar o p_T dos múons em eventos com exatamente um múon, usamos a máscara `single_muon_mask` como um índice:

```
branches['Muon_pt'][single_muon_mask]
```

```
#Saída:<Array [[3.28], [3.84], ... [13.3], [9.48]] type='13447 * var * float32'>
```

```
len(branches['Muon_pt'][single_muon_mask])
```

```
#Saída: 13447
```


Análise de forma Colunar - Seleções



Construindo os 4-momenta dos múons:

```
two_muons_mask = branches['nMuon']== 2
```

Com o pacote [Vector](#), podemos construir os quadrimomentos dos múons a partir das variáveis p_T , η , ϕ , e massa:

```
import vector
```

```
muon_p4 = vector.zip({'pt': branches['Muon_pt'],  
                      'eta': branches['Muon_eta'],  
                      'phi': branches['Muon_phi'],  
                      'mass': branches['Muon_mass']})
```

```
two_muons_p4 = muon_p4[two_muons_mask]
```

Agora podemos acessar propriedades como p_T , η , ϕ , E , e $mass$ dos múons filtrados.

Análise de forma Colunar - Seleções

Para calcular a massa invariante dos dois múons em cada evento, somamos os quadrivetores. Primeiro, selecionamos o quadrimomento do primeiro múon em cada evento usando o slicing[:, 0]:

```
first_muon_p4 = two_muons_p4[:, 0] #primeiro múon de cada evento
```

```
second_muon_p4 = two_muons_p4[:, 1] #segundo múon de cada evento
```

Agora podemos somar os quadrivetores e calcular a massa invariante dos dois múons para cada evento.

```
sum_p4 = first_muon_p4 + second_muon_p4 #o resultado é um array 1D
```

```
two_muons_charges = branches['Muon_charge'][two_muons_mask]
```

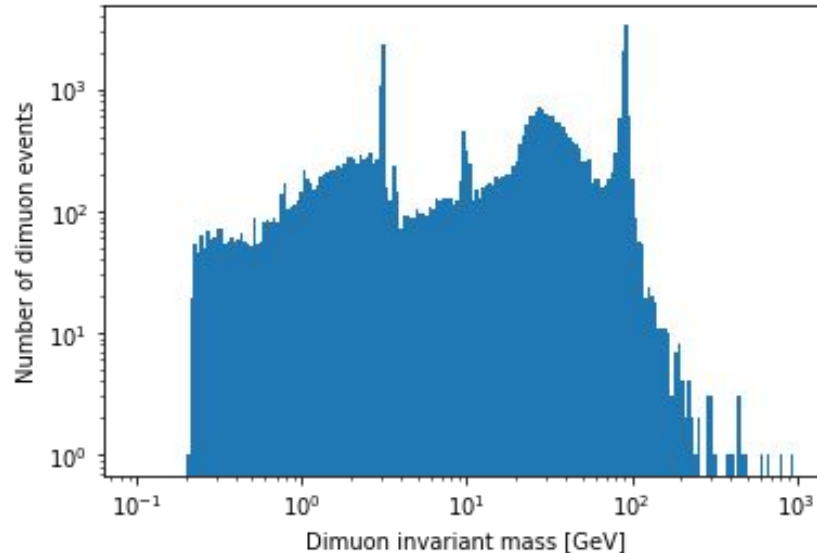
```
opposite_sign_muons_mask = two_muons_charges[:, 0] != two_muons_charges[:, 1]
```

Por fim, aplicamos essa máscara ao somatório dos quadrivetores para obter os eventos de múons de sinais opostos:

```
dimuon_p4 = sum_p4[opposite_sign_muons_mask]
```

Massa invariante dos pares de múons de cargas opostas

```
plt.hist(dimuon_p4.mass, bins=np.logspace(np.log10(0.1), np.log10(1000), 200))  
plt.xlabel('Dimuon invariant mass [GeV]')  
plt.ylabel('Number of dimuon events')  
plt.xscale('log')  
plt.yscale('log')  
plt.show()
```



Referências

- N. Leonardo
- 16th Portuguese Language Teacher Programme
- Particle physics with the computer

Backup

Multiple files and large files

```
uproot.concatenate({'*.root': 'Events'})
```

Another method is to iterate through the entries across all files:

```
for events in uproot.iterate({'*.root': 'Events'}, step_size=100):  
    # do something with events
```

HLT_IsoMu24: o múon deve ter um momento transversal (p_T) superior a 24 GeV. Além de passar o corte de p_T , o múon também deve satisfazer um critério de isolamento.

O isolamento é uma seleção que busca excluir múons que possam estar associados a jatos de partículas ou a decaimentos hadrônicos. Ele é feito somando o momento das partículas em um cone ao redor do múon; quanto menor essa soma em relação ao p_T do múon, mais isolado ele é.

O que é o múon?

- Um múon é um lépton. É o primo mais pesado do elétron.
 - Massa do múon $\sim 105,7 \text{ MeV} \Rightarrow m_\mu/m_e \sim 200$.
 - O múon possui carga elétrica (+,-).
 - Participa das interações eletromagnéticas e fracas, mas não das interações fortes.
- No que os múons decaem?
 - $\text{BR}(\mu \rightarrow e \bar{\nu}) \sim 1$. Como isso funciona?
 - E quanto ao decaimento $\mu \rightarrow e \gamma$?
- Se os múons decaem, como conseguimos observá-los no CMS?
 - A vida média do múon é $\tau \sim 2,2 \times 10^{-6} \text{ s} \Rightarrow c\tau \sim 660 \text{ m}$!
 - Qual é a distância típica entre o ponto de colisão e o início das câmaras de múons?
- Como a vida média do múon se compara à de outras partículas?
 - Por que a vida média do múon é tão longa?
 - Qual é o impacto disso?

Por que nos importamos com os múons?

- Múons são produzidos em interações fracas
 - Se um múon está presente no estado final, um W, Z ou H deve ter estado envolvido.
 - O estudo da física eletrofraca é uma das principais missões do LHC e do CMS.
 - Ou uma nova física está próxima. A busca por física além do Modelo Padrão é a outra grande missão.
- Múons podem ser um indicador útil de física potencialmente interessante
 - Se conseguirmos diferenciar entre múons de W, Z ou H (múons pontuais) e aqueles de outras fontes.
 - Durante este exercício, discutiremos maneiras de fazer isso e como os múons podem ser usados em uma medida ou busca.
- O detector CMS foi projetado para detectar e identificar múons com alta eficiência e medir seu momento e carga em uma ampla faixa de parâmetros cinemáticos.

identificação de múons

Identificação de Múons para Diferenciar Fontes: A identificação de múons é essencial para distinguir entre diferentes origens de múons. Em um experimento como o CMS, múons podem ser produzidos por vários processos, como decaimentos de quarks pesados, decaimentos de partículas instáveis ou mesmo como parte do ruído de fundo. A escolha de critérios de identificação específicos ajuda a diferenciar entre esses casos.

IDs Baseados em Partícula Fluida (Particle Flow, PF):


- **Loose ID:** Focado em uma alta eficiência para todos os tipos de múons, sem restrições rigorosas. É útil para quando se quer captar o máximo de múons possíveis, inclusive aqueles de fontes secundárias.
- **Medium ID** (CutBased e MVA-based): Alta eficiência para múons prompt (múons originados diretamente da colisão, não de decaimentos secundários) e decaimentos de quarks pesados (como o quark charm e o bottom).
- **Tight ID** (CutBased e MVA-based): Alta eficiência especificamente para múons prompt, sendo mais seletivo e usado quando há necessidade de maior certeza de que o múon seja "prompt".

Outros Tipos de IDs Específicos:


- **High p_T ID:** Projetado para selecionar múons de alto momento transversal ($p_T > 200 \text{ GeV}$) com alta eficiência e qualidade de reconstrução. Esses múons não são mais minimamente ionizantes (MIPs) e perdem energia ao passar pelo sistema de detecção de múons, o que torna a identificação um pouco mais complexa.
- **SoftID/SoftMVA ID:** Específico para a física de b-quarks (b-física), onde é comum lidar com múons de baixa energia resultantes de decaimentos de quarks pesados.
- **MVA ID:** Baseado em uma técnica de Machine Learning (MVA - Multi-Variate Analysis) para fornecer alta eficiência em identificar múons prompt e decaimentos de quarks pesados.
- **Prompt MVA:** Um identificador que combina critérios de isolamento, parâmetros de impacto e outras variáveis para selecionar múons prompt com grande pureza, essencial quando é necessário reduzir a presença de ruído de fundo.

ajuste aos dados

Modelo simplificado: Gaussiana (sinal) + polinomial (bckg)



Como poderíamos melhorar?
 dica: final-state radiation




e essa distribuição com yield alto,
 não está bem descrita, por quê?

3.8T Superconducting Solenoid

Hermetic ($|\eta| < 5.2$)
Hadron Calorimeter (HCAL)
[scintillators & brass]

Lead tungstate
E/M Calorimeter (ECAL)



All Silicon Tracker
(Pixels and Microstrips)



Redundant Muon System
(RPCs, Drift Tubes,
Cathode Strip Chambers)

Campo magnético: no coração de uma experiência

Cargas elétricas em movimento são sensíveis aos campos magnéticos

A partir da trajetória de uma partícula sujeita a B :

- *direcção*
⇒ medição da carga eléctrica
- *raio de curvatura*
⇒ medida de momento (conhecida a massa)
⇒ medida de massa (conhecida a velocidade)



$$p \cos \lambda = 0.3 z B R$$

momento linear [GeV/c] ângulo de inclinação carga eléctrica [e] intensidade de campo magnético [T] Raio de curvatura [L]